Décisions techniques

Chaque décision est consignée avec son contexte, les alternatives écartées et ce qu'elle coûte. Le but est double : ne pas rediscuter dix fois la même chose, et pouvoir répondre en soutenance à « pourquoi ce choix ? » autrement que par « c'est ce qu'on connaissait ».

---

001 — Back-end en Python / FastAPI

Date : 12 octobre 2026 · **État** : accepté

Contexte. La première version du back était en Node/TypeScript, héritée de SkillMatch. L'énoncé autorise explicitement Node comme Django ou Flask : les deux sont conformes.

Décision. Migrer vers Python 3.12+ / FastAPI / Pydantic / SQLAlchemy.

Alternatives.

- *Rester sur Node* — zéro coût immédiat, mais extraction PDF faible et écosystème moins mûr pour le traitement de textes longs.
- *Next.js en monolithe* — le chemin le plus court vers un déploiement, écarté parce que l'énoncé insiste sur « front-end + back-end » et qu'un monolithe se défend moins bien en deux tiers à l'oral.

Raisons. La documentation OpenAPI est produite automatiquement et sert de pièce au rapport. PyMuPDF respecte l'ordre de lecture sur les mises en page à deux colonnes, fréquentes dans un support de cours. Et tous les ateliers du module sont en Python : le correcteur lit du Python toute l'année.

Conséquences. Positif : `/docs` gratuit, extraction PDF correcte, tests rapides. Coût : deux écosystèmes au lieu d'un, et les types du front doivent rester cohérents avec les schémas du back à la main. Égalité réelle sur la validation — Pydantic et Zod se valent, prétendre le contraire serait malhonnête.

---

002 — Découper les cours longs plutôt que les tronquer

Date : 12 octobre 2026 · **État** : accepté

Contexte. La version précédente coupait à 20 000 caractères et envoyait le début. Un cours de soixante pages était donc résumé à partir de son premier tiers, **sans aucun signalement**. Le pire genre de défaut : le résultat a l'air correct.

Décision. Découper en segments respectant les paragraphes, puis les phrases, avec recouvrement. Résumé par agrégation, quiz sur segments échelonnés, tuteur sur segments sélectionnés.

Alternatives.

- *Augmenter simplement la limite* — les modèles actuels encaissent de très longs contextes, mais la qualité se dégrade au milieu, et le coût croît.
- *Laisser tronquer en l'annonçant* — honnête mais inutile.

Conséquences. Positif : plus rien ne disparaît en silence ; si une limite subsiste, elle apparaît dans les `warnings`. Coût : **le nombre d'appels est multiplié**. Atténué par le cache des résumés, le plafonnement par module, et le choix de la taille de segment — voir décision 012.

---

003 — Sessions synchrones plutôt qu'asynchrones

Date : 12 octobre 2026 · **État** : accepté

Contexte. FastAPI invite à écrire des routes `async`. Le pooler de transactions de Supabase interdit les requêtes préparées, ce qui demande une configuration délicate en asyncpg et produit des pannes difficiles à diagnostiquer.

Décision. Routes `def`, sessions SQLAlchemy synchrones. FastAPI les exécute dans un pool de fils d'exécution.

Raison. Le gain serait nul à notre échelle : quelques étudiants, et un appel au modèle de plusieurs secondes qui domine de toute façon la latence.

Conséquence. À très forte charge il faudrait reconsidérer. Ce n'est pas le cas d'usage.

---

004 — Appeler les fournisseurs en HTTP direct, sans SDK

Date : 12 octobre 2026 · **État** : accepté

Décision. `httpx` plutôt que `google-generativeai` et `anthropic`.

Raisons. La requête est visible dans le code, donc explicable en soutenance. La traduction des défaillances dans notre taxonomie est entièrement maîtrisée — un SDK masque les codes HTTP derrière ses propres exceptions. Et une dépendance de moins par fournisseur.

Conséquence. Il faut suivre soi-même les évolutions d'API. Acceptable : deux fournisseurs, deux points d'entrée.

---

005 — Recherche lexicale (BM25) plutôt que plongements

Date : 12 octobre 2026 · **État** : accepté, à réexaminer

Contexte. Le tuteur doit choisir quels passages envoyer. Deux approches : comparer les **mots** (BM25) ou comparer le **sens** (plongements).

Décision. BM25 pour l'instant.

Alternatives.

- *Plongements par l'API Gemini* — même clé, aucune dépendance nouvelle, déploiement inchangé. Consomme du quota.
- *Plongements locaux via Hugging Face* — ne consomme aucun quota, mais ajoute PyTorch et un modèle de plusieurs centaines de méga-octets, ce qui rend l'hébergement gratuit improbable. Or l'énoncé demande une application « idéalement déployée ».

Raison. Sur un corpus de la taille d'un cours — vingt à soixante pages — la recherche sémantique rapporte peu. Trois segments couvrent déjà une grande partie du document, et le modèle lit très bien ce qu'on lui donne. La sélection n'a pas besoin d'être brillante pour que la réponse soit bonne. Les plongements amélioreraient un maillon qui n'est pas celui qui limite la qualité.

Limite assumée. Une question qui n'emploie aucun mot du cours sera mal servie. Documenté dans `services/segmentation.py`.

À réexaminer. La comparaison BM25 / plongements, mesurée sur un jeu de questions dont on connaît la bonne réponse, est un excellent sujet pour le banc d'essai (AA5). Un résultat négatif mesuré vaut mieux qu'une fonctionnalité ajoutée sans preuve.

---

006 — Anonymiser une fois, avant le découpage

Date : 12 octobre 2026 · **État** : accepté

Contexte. Avec le découpage, le masquage pouvait se faire segment par segment.

Décision. Masquer le cours **entier** d'abord, découper ensuite.

Raison. Des jetons numérotés indépendamment par segment donneraient `[NOM_1]` désignant une personne dans un segment et une autre dans le suivant. L'agrégation mélangerait les identités.

Conséquence. La question de l'étudiant et l'historique doivent être masqués dans le **même** passage que le cours, pour partager la table de jetons. D'où l'astuce de la cloison : les trois textes sont assemblés avec un séparateur unique, masqués ensemble, puis redécoupés.

---

007 — Un seul type d'utilisateur

Date : 10 octobre 2026 · **État** : accepté

Décision. Pas de rôle enseignant, pas d'administrateur.

Raison. Le sujet ne décrit qu'un étudiant qui importe ses cours. Ajouter des rôles serait inventer une exigence.

Conséquence. Pas de garde par rôle : la seule règle d'accès est la propriété, vérifiée côté serveur. Le code en est simplifié, et la sécurité plus facile à démontrer.

---

008 — Garder le masquage des noms malgré sa faible utilité

Date : 12 octobre 2026 · **État** : accepté

Contexte. Le module d'anonymisation vient de SkillMatch, où l'entrée était un CV. Dans un support de cours, le risque est tout autre.

Décision. Conserver le module entier, mais **requalifier sa justification** dans le rapport : les secrets et les coordonnées de tiers, pas les données de l'étudiant.

Raison. L'énoncé l'exige explicitement. Et le risque réel est démontrable : un fichier distribué dans ce module contient un jeton Hugging Face en clair.

Limite écrite. Les patronymes ne sont pas détectés, et un test le documente. Mieux vaut l'énoncer que le laisser découvrir.

---

009 — Base SQLite acceptée en plus de PostgreSQL

Date : 12 octobre 2026 · **État** : accepté

Décision. Déclarer les colonnes JSON en `JSONB` avec une variante `JSON`, et ne passer les options psycopg qu'en PostgreSQL.

Raison. Permet d'exécuter la suite de tests de bout en bout sans base distante ni conteneur. Une chaîne de traitement qu'on ne peut pas exécuter en test n'est vérifiée par personne.

Effet de bord utile. L'application entière tourne en local sans Supabase, ce qui a débloqué la démonstration pendant que le projet Supabase n'existait pas encore.

---

010 — Ports distincts de SkillMatch

Date : 12 octobre 2026 · **État** : accepté

StudyAI : front **5174**, back **3002**. SkillMatch garde 5173 et 3001. Les deux projets doivent pouvoir tourner en même temps.

---

011 — Mélanger les options du quiz côté serveur

Date : 13 octobre 2026 · **État** : accepté

Contexte. À la première série de quiz enregistrés en base, **cinq bonnes réponses sur six se trouvaient en position A**. Un QCM dont la réponse est presque toujours la première n'évalue rien : l'étudiant apprend la position, pas le cours. Le défaut n'était visible qu'en regardant les données, pas en lisant une question isolée.

Décision. Redistribuer la position de la bonne réponse dans le code, après validation et avant enregistrement (`pipeline.melanger_options`).

Alternative écartée. Ajouter au prompt « varie la position de la bonne réponse ». Ce serait confier une garantie à l'obéissance du modèle, alors qu'une ligne de code la rend certaine. Même raisonnement que pour la règle d'anonymisation : ce qui doit être garanti est porté par la structure, pas par la consigne.

Conséquence. Un test unitaire vérifie que les positions varient **et** que le mélange ne change jamais *quelle* réponse est correcte. Un test existant, qui supposait une position fixe, a dû être réécrit : il testait la doublure du modèle, pas la correction.

---

012 — Segments de 24 000 caractères plutôt que 8 000

Date : 13 octobre 2026 · **État** : accepté

Contexte. La taille des segments gouverne directement la consommation de quota : un résumé coûte un appel par segment, plus un appel d'agrégation. Or Google ne publie plus les limites du palier gratuit de Gemini, et plusieurs sources rapportent des baisses importantes courant 2026. Tomber à court de requêtes pendant la démonstration est le risque le plus concret du projet.

Décision. Porter `SEGMENT_CHARS` de 8 000 à 24 000.

Mesure sur le même cours (`Prompt Engineering.pdf` , 26 040 caractères) :

SEGMENT_CHARS	Segments	Appels	Jetons	Latence	Points clés
8 000	4	5	9 389 + 2 299	22 392 ms	10
24 000	2	3	7 391 + 1 398	18 735 ms	8

Raison. 40 % d'appels en moins pour un résumé un peu moins granulaire. La valeur initiale de 8 000 était prudente : elle datait d'avant toute mesure, et les modèles actuels encaissent des contextes bien plus larges.

Ce que ça coûte. Un grain de synthèse plus grossier — huit points clés au lieu de dix. Sur un cours de vingt-six mille caractères, l'écart est réel mais sans conséquence pédagogique.

Ce que ça ne change pas. Aucun contenu n'est perdu dans les deux cas : le cours est traité en entier, et une éventuelle amputation reste signalée dans les `warnings` .

Réversible. C'est une variable d'environnement. Un groupe disposant d'un quota confortable peut revenir à 8 000 sans toucher au code.

---

013 — Des erreurs qui disent quoi faire, et un garde-fou contre la page blanche

Date : 13 octobre 2026 · **État** : accepté

Contexte. Le bandeau d'erreur disait ce qui s'était passé — *« Le quota d'analyses est atteint »* — et s'arrêtait là. L'étudiant restait devant un rectangle rouge sans issue. Par ailleurs, une exception JavaScript dans un composant démontait tout l'arbre React et laissait une **page blanche** : ni message, ni recours, et rien pour comprendre.

Décision. Trois mesures.

1. `lib/erreurs.ts` associe à chaque code une **famille**, une **conduite à tenir** et un indicateur `reessayable`. Le bandeau affiche une icône, le message, le conseil, les actions possibles et le code technique.
2. Un **garde-fou React** (`components/GardeFou.tsx`) entoure les routes — mais pas l'en-tête, pour que l'utilisateur garde sa navigation même si une page s'effondre.
3. Une **page Figma dédiée** rend les onze codes tels qu'ils s'affichent.

Le point qui compte. `reessayable` reflète exactement la politique de reprise du serveur : pas de bouton « Réessayer » sur un quota épuisé, une clef refusée ou un délai dépassé, parce que **le serveur lui-même ne réessaie pas** dans ces cas. L'interface ne promet rien que le back ne tienne.

Alternative écartée. Une page pleine par code d'erreur. Ce serait un recul : quand un résumé échoue, l'étudiant doit garder son cours à l'écran et pouvoir relancer. Le bandeau contextuel est le bon motif pour une erreur récupérable ; les pages pleines sont réservées aux cas sans contexte à préserver — page introuvable, session expirée, erreur inattendue.

Défaut trouvé au passage. Une panne réseau faisait rejeter `fetch` avec un `TypeError`, qui n'a ni code ni message utilisable : l'interface sortait de son propre contrat d'erreur dès que le serveur était injoignable, et affichait « Failed to fetch ». Rattrapé dans `lib/api.ts`, avec un conseil spécifique.

---

014 — reportlab pour la fiche de révision, pas la chaîne Markdown → Chrome

Date : 13 octobre 2026 · **État** : accepté

Contexte. Le projet produit déjà des PDF avec `tools/md2pdf.py`, qui passe par Chrome en mode sans interface. La fiche de révision aurait pu réutiliser cette chaîne.

Décision. Produire la fiche avec `reportlab`, directement en Python.

Raison. `md2pdf.py` convient à une conversion lancée à la main, pas à une requête HTTP : il dépend de la présence de Chrome sur la machine hôte et met plusieurs secondes. reportlab rend la main en quelques dizaines de millisecondes et n'a aucune dépendance système.

Alternative écartée : `weasyprint`, qui convertirait du HTML et permettrait de réutiliser la charte. Il réclame GTK et Pango, pénibles à installer sous Windows — et l'équipe travaille sous Windows.

Conséquence. Une dépendance de plus, et une mise en page décrite en Python plutôt qu'en CSS. Les deux chaînes coexistent : Chrome pour les documents du dépôt, reportlab pour ce que l'application sert à chaud.

---

015 — Accentuer les prompts, et lier le cache à leur version

Date : 13 octobre 2026 · **État** : accepté

Contexte. Défaut constaté en imprimant la première fiche de révision : les sorties du modèle revenaient **en français sans accents**. « Ce cours presente les ateliers du module… ». La cause n'était pas la bibliothèque PDF — vérifié, reportlab rend les accents sans difficulté — mais le texte stocké en base.

Le modèle imitait le style des consignes, elles-mêmes écrites sans accents par une convention de code destinée à la console Windows. Cette convention n'avait aucune raison de s'appliquer à du texte envoyé au modèle.

Décision. Un fragment `LANGUE` partagé, **lui-même accentué**, ajouté aux quatre prompts, qui passent en v3.

Et une seconde décision, plus importante. La version du prompt entre dans la clé de cache des résumés. Sans elle, cette correction serait restée invisible : les résumés déjà produits continuaient à s'afficher sans accents. Toute amélioration future des consignes se propage désormais d'elle-même.

Ce que ça coûte. Un changement de prompt invalide le cache et relance les analyses — donc consomme du quota. C'est le prix d'une correction qui prend effet.

Leçon. Un défaut invisible à l'écran peut être criant à l'impression. Ce sont les livrables qui sortent de l'écran — ici une fiche imprimée — qui révèlent ce genre de chose.

---

016 — Refuser un cours trop long, et plafonner les appels au modèle

Date : 13 octobre 2026 · **État** : accepté

Contexte. Une revue du projet a trouvé deux trous que la documentation contredisait.

Le premier. `routers/courses.py` coupait le contenu à `MAX_COURSE_CHARS` sans rien dire. Mesuré : 476 000 caractères envoyés, 200 000 stockés, **276 000 perdus**, HTTP 201, aucun avertissement. C'est exactement le défaut que le découpage avait corrigé plus loin dans la chaîne — mais à l'import, là où l'utilisateur regarde.

Décision. Refuser en 400, avec le nombre de caractères en trop et la limite. Plutôt que tronquer avec un avertissement : l'étudiant sait quoi faire, au lieu de croire son cours complet. Un cours de plus de 200 000 caractères — soixante pages — gagne de toute façon à être découpé.

Le second. `RATE_LIMITED` figurait dans la taxonomie depuis le début sans qu'aucune route ne l'émette. Un double-clic suffisait à déclencher deux générations de quiz ; dix clics épuisaient le quota du jour, au pire

moment.

Décision. Une fenêtre glissante en mémoire, dix appels par minute et par utilisateur, posée uniquement sur les trois routes qui appellent le modèle. Consulter ses cours ou sa progression ne coûte rien et n'est pas plafonné.

Ce que ça ne fait pas. Ne protège pas d'un abus déterminé : un utilisateur peut créer plusieurs comptes. L'objectif est d'éviter l'accident. Et sur plusieurs instances, il faudrait un magasin partagé.

Leçon. Les deux défauts étaient des **écarts entre la documentation et le code** : une garantie affirmée mais contournable, et un code d'erreur qui ne pouvait pas survenir. Ce sont les plus dangereux, parce que personne ne les surveille — on croit le problème traité.

---

017 — Lire aussi les `.docx` et les `.pptx`, et les lire correctement

Date : 13 octobre 2026 · **État** : accepté

Contexte. StudyAI n'acceptait que le PDF. Or les supports de ce module sont distribués en **PowerPoint** pour les cours et en **Word** pour les ateliers : sur les neuf fichiers de l'énoncé, aucun n'est un PDF. L'étudiant devait donc convertir chaque fichier à la main avant de pouvoir s'en servir — un travail que la machine fait mieux, et qui dégradait au passage la mise en page.

Décision. Trois lecteurs derrière une seule entrée, `services/extraction.py`. PyMuPDF pour le PDF, python-docx et python-pptx pour le reste : deux bibliothèques **Python pures**, donc rien à installer sur le poste — le même critère qui avait fait écarter weasyprint au profit de reportlab (décision 012).

Le format est choisi sur l'extension, pas sur le type MIME

Le navigateur annonce le type que le système d'exploitation lui souffle, et Windows envoie régulièrement `application/octet-stream` pour un `.pptx` selon l'application qui a créé le fichier. **Mesuré** : deux des cinq supports d'essai sont arrivés en `application/octet-stream`. Un contrôle sur le type MIME les aurait refusés.

L'extension, elle, est ce que l'étudiant voit. Et elle n'est pas le dernier mot : le format réel est vérifié juste après, par le lecteur lui-même — python-docx refuse une archive qui n'est pas un paquet Word. *L'extension oriente, le lecteur tranche.* Le même critère est appliqué côté navigateur (`accept=".pdf,.docx,.pptx"`), de sorte que les deux filtres ne peuvent pas diverger.

Trois défauts d'extraction, trouvés en sondant les vrais fichiers

Aucun des trois n'aurait produit d'erreur. Tous les trois auraient dégradé silencieusement la qualité des résumés — la pire catégorie de défaut sur ce projet.

Défaut	Mesure sur les supports du module
`document.paragraphs` **ignore les tableaux**	271 caractères sur 1 602 dans `Atelier 3.docx`, soit **17 %** — et dans un atelier, le tableau est la grille de notation
`slide.shapes` suit l'ordre d'**empilement**, pas de lecture	Diapo 2 de `Chapitre5.pptx` : titre → **numéro de page** → image → corps. Les 54 diapos injectaient 54 chiffres orphelins
Espaces de **largeur nulle** (`\u200b`) au milieu des mots	Présents dans `Prompt Engineering.pptx`. Invisibles, mais ils brisent un mot pour toute comparaison de chaînes

Le troisième mérite un mot : il n'est cosmétique qu'en apparence. Un caractère invisible dans un mot fait échouer le contrôle d'**ancrage du quiz** sur une citation parfaitement fidèle, et produit des jetons fantômes dans le découpage en mots de **BM25**. C'est le même piège que l'ancrage strict du banc d'essai (EVALUATION.md section 5) : la mesure et le texte doivent parler la même langue.

Les notes de l'orateur sont incluses — et c'est une décision de fond

Sur un diaporama de cours, les diapositives sont télégraphiques et l'explication vit dans les notes. **Mesuré sur `séance1-Introduction.pptx` : 42 diapositives sur 50 portent des notes, qui représentent 31 % du texte du support.** Les écarter, c'était résumer le squelette d'un cours en ignorant le cours.

Vérifié par un vrai appel : à la question « dans quels domaines autres que le logiciel l'IA est-elle présente ? », le tuteur répond « santé, finance, industrie » **et cite la note comme source**. Les trois mots sont absents des diapositives et présents dans les notes — contrôlé par programme. Sans les notes, le tuteur aurait refusé cette question, à juste titre et pour une mauvaise raison.

Le coût, honnêtement. Certaines notes sont des mémos de production et non de la pédagogie : `Chapitre5.pptx` contient « Logo EUR-ACE » et « Taille 54 ». Elles entrent dans le cours. Nous ne les filtrons pas, parce qu'aucune règle ne distingue un mémo d'une explication sans risquer d'écarter du contenu réel — et parce que 31 % de contenu utile vaut mieux qu'une poignée de notes de mise en page.

Le plafond de taille passe de 8 à 25 Mo

Un diaporama est très défavorable sur le rapport octets/texte : `séance1-Introduction.pptx` pèse 4,6 Mo pour 29 000 caractères utiles, soit **160 octets par caractère** — le reste est en images. Ce support passait sous l'ancien plafond, mais sans marge. Le format et la taille sont vérifiés **avant** la lecture des octets, ce qui préserve la correction de la décision 016.

Leçon. Les trois défauts d'extraction ont été trouvés en **sondant les vrais fichiers avant d'écrire le lecteur**, pas en relisant la documentation des bibliothèques. Un extracteur naïf aurait fonctionné sans jamais lever d'erreur, en perdant un tiers du cours.

---

018 — Examen blanc multi-cours, et pourquoi il ne coûte rien

Date : 13 octobre 2026 · **État** : accepté

Contexte. La boucle de révision s'arrêtait à « un cours, un quiz ». Or avant un examen réel, un étudiant révise **plusieurs chapitres à la fois**, et veut savoir s'il tient dans le temps imparti. C'était la pièce manquante entre « générer des questions » et « se préparer ».

La propriété centrale : zéro appel au modèle

Les questions viennent des **quiz déjà générés**, qui sont en base. Composer un examen de vingt questions sur quatre cours ne déclenche donc aucun appel : l'étudiant peut en passer dix dans l'heure sans entamer son quota. Sur un projet contraint par un palier gratuit, c'est la différence entre une fonctionnalité utilisable et une démonstration unique.

La génération des questions manquantes existe, mais elle est **demandée explicitement** (`completer: true`), annoncée comme payante dans l'interface, et soumise au plafond de débit. Jamais déclenchée en silence.

Cette propriété est **vérifiée par un test**, pas seulement affirmée : `test_composer_un_examen_n_appelle_pas_le_modele` compte les appels à la doublure avant et après. Une affirmation de coût qui n'est pas testée est une affirmation qui dérivera.

Les questions sont figées dans la ligne, pas référencées

Un examen aurait pu stocker des couples (quiz, rang). Il stocke une copie des questions. **Duplication assumée** : un quiz peut être régénéré ou supprimé, et un examen passé la semaine dernière doit rester corrigible exactement tel qu'il a été passé. Un examen dont la correction change après coup ne vaut rien comme trace de révision. La normalisation cède devant la reproductibilité.

Pour la même raison, la table `exams` est rattachée à l'**étudiant** et non à un cours : supprimer un cours ne doit pas emporter l'examen qui portait aussi sur les trois autres.

Le temps est mesuré, pas imposé

Le serveur fait foi sur la durée écoulée — il recalcule `remainingS` à chaque lecture, donc trafiquer l'horloge du navigateur ne donne rien. Mais une copie rendue en retard est **corrigée quand même**, et simplement marquée. Un outil de révision n'a aucune raison de punir : l'étudiant veut savoir s'il a dépassé, pas perdre son travail.

En revanche, une copie déjà rendue **ne peut pas l'être deux fois**. Sans ce garde-fou, il suffirait de lire le corrigé puis de renvoyer le formulaire.

Le déficit de questions est redistribué, et signalé

Demander dix questions sur deux cours dont l'un n'en a que trois en rend **dix**, pas huit : le déficit est repris sur le cours qui a du stock, par tours successifs pour ne pas faire porter tout le rattrapage au premier cours venu. Et l'étudiant est averti que l'équilibre n'a pas été tenu, avec le détail par cours.

Un filtre mesuré, puis écarté

Deux quiz successifs sur le même cours reposent souvent la même question. Le dédoublonnage compare les énoncés normalisés — accents, ponctuation et casse retirés — ce qui attrape les reformulations de surface.

Il laisse passer les **doublons sémantiques**. Observé en conditions réelles : « Quel est le prix de base par nuit pour une chambre standard *dans le fichier booking_engine.py* ? » et « … *selon le cours* ? » se sont retrouvées dans le même examen.

Un filtre par similarité de Jaccard semblait la réponse évidente.

> **Correction du 13 octobre, en fin de journée.** La première rédaction de cette décision justifiait le refus par une mesure : un doublon réel à 0,63 contre deux questions légitimes à 0,75, donc des populations qui se chevauchent. **Ce contre-exemple à 0,75 était inventé** — écrit à la main pour éprouver l'idée, pas tiré des données. Justifier un refus par un chiffre fabriqué est précisément le défaut que ce projet reproche ailleurs. La mesure a été refaite sur les données réelles ; elle ne dit pas la même chose, et la conclusion a changé de raisons.

Ce que disent les données réelles

Sur les 18 questions en base, soit 88 paires issues d'un même cours :

Seuil de Jaccard	Paires supprimées	Faux positifs observés
0,55	5	**0**
0,65	3	**0**
0,70	1	**0**

Les cinq paires au-dessus de 0,55 sont **toutes** de vrais doublons, jusqu'à 0,88 pour « Quel message d'erreur s'affiche… » contre « Quel est le message d'erreur affiché… ». Aucune paire légitime n'atteint ce niveau dans les données observées. **Le filtre est donc mieux fondé que la première rédaction ne le prétendait.**

Une seconde piste a été mesurée puis écartée pour de bon : dédoublonner sur la **citation source identique**, en supposant que deux questions tirées du même passage testent le même fait. Résultat : **3 doublons pour 3 faux positifs**, une pièce de monnaie. Deux questions parfaitement distinctes naissent couramment du même passage — « quel langage pour les scénarios ? » et « quel outil de test comportemental ? ».

Pourquoi le filtre n'est quand même pas en place

Trois raisons, dont aucune n'est celle qui avait été écrite :

1. **L'échantillon est minuscule** : 18 questions, 2 cours, un seul domaine. Calibrer un seuil là-dessus est du surapprentissage. Rien ne garantit que la fenêtre propre 0,55–0,65 survive à un cours de droit ou de mathématiques.
2. **L'erreur du filtre serait invisible.** Un doublon qui passe, l'étudiant le voit et hausse les épaules. Une question légitime supprimée, personne ne sait qu'elle a existé. Le bénéfice se constate, le coût jamais : c'est la pire forme possible pour une heuristique, parce qu'elle aura toujours l'air de fonctionner.
3. **L'enjeu reste faible** : un doublon coûte une question gâchée sur vingt.

La fréquence, en revanche, avait été sous-estimée : **5 paires proches sur 18 questions**, soit près d'une question sur trois impliquée. Sur un examen de dix questions, il faut s'attendre à un ou deux doublons.

Ce qui a été fait à la place : déprioriser, pas supprimer

À la composition, chaque question est choisie en préférant celle qui ressemble le moins à celles déjà retenues ; si le stock ne suffit pas, une question proche est prise **quand même**. La raison n° 2 disparaît entièrement : rien n'est perdu en silence, l'examen garde son compte exact, et un doublon n'apparaît que faute d'alternative. Le seuil cesse d'être une suppression irréversible pour devenir une préférence.

La diversité est calculée sur l'**examen entier**, pas cours par cours : une question du second cours proche d'une question déjà retenue dans le premier est dépriorisée elle aussi.

Mesure, sur les 18 questions en base, 2 000 compositions par ligne :

Questions demandées	Doublons au hasard	Avec dépriorisation	Examens sans doublon
5	0,33	**0,00**	70 % → **100 %**
8	0,91	**0,00**	35 % → **100 %**
10	**1,47**	**0,00**	**16 %** → **100 %**
12	2,13	**0,00**	4 % → **100 %**
14	2,94	**0,00**	0 % → **100 %**

Au point d'usage normal — dix questions tirées de dix-huit — un examen sur six seulement était exempt de doublon. **Aucune question perdue sur 10 000 compositions.**

Deux réserves, dites plutôt que tues. Le « 0,00 » n'est pas une garantie : il tient parce que ce vivier est peu dense en répétitions, et sur un vivier plus riche le glouton n'aurait pas toujours d'alternative. Ce qui est garanti, c'est de ne jamais faire pire qu'un tirage au hasard. Et le gain disparaît en dessous de 1,2× de marge de stock : l'étudiant qui demande autant de questions qu'il en possède les prend toutes, doublons compris — ce qui est le comportement correct.

Les tests ne protégeaient d'abord que la fonction, pas son branchement

Six tests couvraient `_choisir_varie`. Deux mutations volontaires de `composer` — revenir à un tirage au hasard, et recalculer la diversité cours par cours — **laissaient les trente-deux tests verts**. On pouvait débrancher la fonctionnalité sans qu'une alerte se déclenche.

Deux tests de plus appellent donc le **service**, avec une graine fixée et des énoncés fabriqués — la doublure du modèle produit des questions toutes proches les unes des autres, ce qui ne permet de distinguer aucun tirage. Les deux mutations tombent désormais.

C'est la troisième fois dans ce projet qu'un test vert ne protège rien. Les trois fois, la cause est la même : avoir vérifié l'unité et supposé le câblage.

Leçon. La première version de cette décision concluait juste pour une mauvaise raison, et c'est plus dangereux qu'une erreur franche : le raisonnement avait l'air mesuré. **Un contre-exemple construit par celui qui veut conclure n'est pas une mesure.** Il faut aller le chercher dans les données, même — et surtout — quand on a déjà son avis.

---

019 — Recherche et tuteur sur toute la bibliothèque

Date : 13 octobre 2026 · **État** : accepté

Contexte. Un étudiant qui révise ne sait pas toujours dans quel chapitre une notion a été vue — c'est souvent la vraie question : « où ai-je vu l'exécution symbolique ? ». StudyAI obligeait à ouvrir chaque cours et à interroger son tuteur l'un après l'autre.

Deux actions, deux coûts, dits explicitement

Route	Coût	Pourquoi
`GET /api/search`	**0 appel**	purement lexical, en local
`POST /api/ask`	**1 appel**, quel que soit le nombre de cours	la sélection des passages est faite avant, gratuitement

Dix cours ne coûtent donc pas dix fois plus cher qu'un seul. Les deux coûts sont **affichés dans l'interface** : sur un palier gratuit, c'est la seule façon pour l'étudiant de savoir ce qu'il consomme.

Et la recherche fonctionne **sans clé d'API** — donc pendant une panne du fournisseur, ce qui est exactement le moment où l'on veut encore pouvoir réviser.

Le BM25 est extrait, pas recopié

La formule vivait dans `selectionner`, au service du tuteur d'un cours. Elle est désormais dans `scores_bm25`, partagée. Deux implémentations de la même formule auraient fini par diverger, et la seconde n'aurait été testée par personne — un test le vérifie explicitement.

Le déplacement a révélé un **coût quadratique** : la fréquence documentaire de chaque terme était recalculée pour chaque segment, soit O(segments² × termes). Invisible sur les trois segments d'un cours, sensible sur les segments de toute une bibliothèque. Elle est maintenant calculée une fois.

L'IDF est calculé sur toute la bibliothèque, pas cours par cours. C'est le point : un mot banal dans un cours mais rare dans les autres pèse alors correctement, ce qui est précisément le signal cherché quand on demande « dans lequel de mes cours ai-je vu ça ? ».

Le découpage est refait à chaque recherche

Les segments ne sont stockés nulle part. Les conserver demanderait une table de plus et une invalidation à chaque modification de cours, pour économiser une suite d'expressions régulières sur du texte déjà en mémoire. Le compromis est assumé ; il deviendrait discutable bien au-delà du volume qu'un étudiant accumule en un semestre.

La limite lexicale, mesurée puis réduite

La recherche compare des **mots**, pas du sens. Une requête qui n'emploie aucun mot du cours ne trouve rien, même si la notion y est (DECISIONS 005).

Un cas précis est apparu à l'essai : **« binome » ne trouvait rien dans** `Atelier 3.docx`, qui écrit pourtant « le travail se fait en binômes ». Pas de racinisation : les jetons sont comparés entiers, et `binomes ≠ binome`. C'est

le ratage le plus fréquent en français, et le plus déroutant — l'étudiant voit le mot de ses propres yeux dans son document.

Corrigé côté requête uniquement : chaque terme cherché est élargi à ses variantes singulier/pluriel. Le choix de l'endroit est délibéré — `scores_bm25` est partagée avec la sélection des passages du tuteur d'un cours, dont les mesures sont publiées dans EVALUATION.md. Modifier la façon dont les termes s'apparient invaliderait ces chiffres ; élargir la requête ne change rien pour l'appelant qui ne le demande pas.

Ce n'est **pas** une racinisation : « tester » ne trouvera toujours pas « test ». La limite est réduite à sa forme la plus gênante, pas supprimée.

Les réponses transversales ne sont pas enregistrées

Un échange qui traverse plusieurs cours ne se rattache à aucun. L'accrocher au cours le plus représenté serait une approximation visible dans l'historique, et créer une neuvième table pour un échange que l'étudiant poursuivra de toute façon dans le tuteur du bon cours ne se justifie pas. Les sources nommant leur cours, le chemin de reprise existe.

Zéro passage : répondre sans appeler

Quand aucun passage ne correspond, la réponse « non couverte » est produite **sans appel au modèle**. Ce n'est pas qu'une économie : c'est plus juste. Le modèle n'aurait eu aucun passage à lire, aurait conclu la même chose, avec en prime le risque de compléter par ses connaissances générales.

Leçon. Les deux décisions les plus structurantes de ce module portent sur l'**endroit** d'un changement, pas sur le changement lui-même : extraire BM25 plutôt que le recopier, et élargir la requête plutôt que la fonction de score. Au mauvais endroit, les deux auraient marché — et abîmé autre chose.

---

020 — Tableau de consommation : montrer ce que l'IA coûte

Date : 13 octobre 2026 · **État** : accepté

Contexte. Toute la télémétrie était enregistrée à chaque opération depuis le premier jour — modèle, version de prompt, température, jetons, latence — et n'apparaissait **nulle part**. Des données collectées que personne ne regarde ne servent à rien ; pire, elles donnent l'illusion d'une mesure.

Sur un module intitulé *IA for Software Engineering*, savoir ce qu'un appel coûte fait partie du sujet. Et sur un palier gratuit, c'est la seule façon de savoir où l'on en est avant de tomber sur un quota épuisé en pleine révision.

Une opération n'est pas un appel — et le compte était jeté

Le pipeline comptait déjà les appels réels (`Telemetrie.appels`) : un par segment, plus l'agrégation pour un résumé long. **Ce compte n'était pas persisté.** Et `segmentCount` ne permet pas de le reconstruire : pour un quiz, le nombre d'appels dépend aussi du nombre de questions demandé *et* de `SEGMENTS_QUIZ`, un paramètre de configuration qui a pu changer depuis. Une formule fragile aurait affiché un chiffre faux avec aplomb.

Migration 0004 : colonne `calls`, **nullable**. Les lignes antérieures restent à `NULL` et sont comptées **à part**, jamais fondues dans le total. Le tableau affiche « — » plutôt que « 0 ».

Trois partis pris contre la fausse précision

1. **Le tarif est affiché avec sa source.** Les prix viennent d'agrégateurs tiers consultés le 13 octobre, qui ne s'accordaient pas entre eux ; la page officielle de Google fait foi. Un chiffre d'argent présenté sans sa provenance se lit comme un fait.
2. **Les opérations sans décompte sont visibles**, pas lissées.
3. **Les économies du cache ne sont pas estimées.** Ce serait le chiffre le plus parlant, et rien ne l'enregistre. La section « ce qui n'a rien coûté » ne montre que ce qui est réellement compté : les examens blancs et les questions qu'ils ont servies.

Leçon. Les trois décisions de ce module portent sur ce qu'il ne faut **pas** afficher. Un tableau de coûts qui arrondit ses trous est pire que pas de tableau : il donne confiance.

---

021 — Refonte visuelle : les jetons, et le plafond de contraste

Date : 13 octobre 2026 · **État** : accepté · *étape 1 sur 5*

Contexte. Retour du commanditaire : l'interface est **pâle**. Le reproche est juste, et il était mesurable — cinq causes, pas une impression :

Cause	Mesure
Page et carte quasi identiques	`#f7f8fa` contre `#ffffff` : **3 %** d'écart de luminance
Aucun système d'élévation	**3** `box-shadow` dans toute la feuille de style
Bordures invisibles	`#e5e7eb` sur blanc = **1,2:1**
Hiérarchie typographique écrasée	base **14 px**, `h1` **26 px** — rapport de 1,86 pour toute l'échelle
Rien ne réagit	**1** `@keyframes`, 5 transitions

La cause la moins évidente est probablement la principale : la marque n'existait qu'en une couleur et sa version claire. Sans gamme, la seule façon de l'employer était l'aplat plein — donc on l'employait peu. Une charte à une seule couleur produit mécaniquement une interface grise.

Décision. Une couche de jetons refaite : gamme de marque en sept valeurs, neutres légèrement **froids** (à côté d'un rouge chaud, un gris pur paraît sale), trois niveaux d'élévation nommés, échelle typographique de base 16 en sept crans, et des durées de mouvement.

Le contraste plafonne le goût, pas l'inverse

C'est le point qui mérite d'être retenu. Le fond de page ayant foncé pour se distinguer des cartes, le texte secondaire devenait trop clair : `#6b7280` tombait à **4,17:1**, sous le seuil AA. Il a donc fallu le foncer aussi.

Puis un lavis teinté a été ajouté en tête de page — deux halos dilués qui colorent l'air autour du titre. Une première version plus soutenue a été **mesurée à 4,21:1** dans le pire cas et **annulée**.

Texte secondaire sur	Avant	Après
Carte blanche	4,83	**6,05**
Fond de page	*4,17 si inchangé*	**5,26**
Lavis chaud	—	**5,20**
Lavis froid	—	**5,00**
Texte principal sur carte	16,69	**17,74**

Tout monte, rien ne descend. **Le caractère vient du filet de titre et de l'élévation, pas de la saturation du fond** — c'est la contrainte qui a décidé, et le résultat n'en est pas moins net.

Une régression introduite et corrigée dans la même heure

Élargir les liens de navigation a produit **68 px de débordement horizontal** sur un écran de 375 px, là où il y en avait zéro. Constaté en mesurant `scrollWidth - clientWidth`, pas en regardant une capture : à cette échelle, l'œil ne voit rien. La barre défile désormais dans son propre cadre.

L'en-tête passe au passage de 179 à **153 px**, et devient collant.

Ce que cette étape ne fait pas

Elle pose les jetons et traite l'en-tête, les cartes et les boutons. Les cinq écrans prioritaires, la densité des tableaux de chiffres et les illustrations d'états vides viennent ensuite — voir `PROMPT-REFONTE-VISUELLE.md`.

Leçon. Sur un chantier visuel, **la mesure protège du goût autant que de l'erreur**. Deux fois en une heure, elle a tranché contre ce qui paraissait mieux à l'écran : un lavis trop saturé, et une navigation plus aérée qui cassait le téléphone.

Étape 2 — l'écran d'authentification

> Ajouté à la décision 021 plutôt qu'isolé : même chantier, mêmes contraintes.

C'est la première image de l'application, et la première de la démonstration. Trois défauts y ont été trouvés, dont deux n'avaient rien de visuel.

Un nombre magique devenu faux. La règle disait `min-height: calc(100vh - 69px)` : 69 px était la hauteur de l'en-tête le jour où la ligne a été écrite. Elle en fait **153** aujourd'hui sur un écran étroit. La hauteur restante est désormais obtenue par le flux — `#root` en colonne flexible, le `main` qui s'étire — et plus aucun chiffre n'est à tenir à jour. *Un nombre magique tiré d'une mesure devient faux dès que la mesure change, et personne ne le remarque.*

Un contraste à six centièmes du seuil. Les descriptions des trois modules étaient en blanc à 85 % d'opacité sur le rouge : **4,53:1**, sur du texte de 13,5 px. Techniquement conforme, pratiquement imprudent — la

moindre retouche du fond le faisait passer sous la barre. Porté à 92 % : **5,14:1**, pour une nuance que personne ne perçoit.

Une valeur en dur dans le TSX. `style={{ fontSize: 22 }}` sur le titre du formulaire, en contradiction avec la règle que la feuille de style énonce elle-même en commentaire. Remplacé par un jeton.

Côté visuel : l'aplat de rouge plein devient un dégradé diagonal du ton soutenu vers le plus sombre, avec un halo qui porte le regard vers le logo et une trame de points estompée vers les bords — assez discrète pour se sentir sans se voir. Les trois modules portent un filet vertical qui reprend celui des titres de page. Le panneau droit, qui était un aplat gris, reçoit le même lavis froid que les pages intérieures.

Gain mesuré sur téléphone : le formulaire commençait sous la ligne de flottaison, il faut compter le panneau rouge entier avant d'atteindre le premier champ. Il démarre maintenant à **503 px sur 812** — visible sans défiler. Aucun débordement horizontal, vérifié par `scrollWidth - clientWidth`.

Étape 3 — la liste des cours

C'est l'écran que le jury regardera le plus longtemps. Le défaut n'était pas d'abord esthétique.

L'action destructrice était la plus visible de la carte. « Supprimer » était un bouton bordé, aligné à droite, du même poids visuel que le titre du cours. Pendant ce temps, l'action principale — ouvrir le cours — n'était qu'un lien sur le titre, sans la moindre affordance : ni survol, ni curseur, ni élévation. *L'interface mettait en avant la seule chose qu'on ne veut pas faire par erreur.*

La suppression devient une icône discrète à 45 % d'opacité, qui ne se colore qu'au survol de la carte. Et la **carte entière** ouvre le cours.

Comment la carte devient cliquable sans balisage invalide. Imbriquer un `<button>` dans un `<a>` est interdit. Le titre porte donc un lien dont le pseudo-élément `::after` couvre toute la carte, et le bouton de suppression repasse au-dessus par `z-index`. Les deux comportements ont été vérifiés par `document.elementFromPoint` plutôt qu'à l'œil :

Vérification	Résultat
Clic à 120 px du bord droit, mi-hauteur	ouvre `/cours/{id}`
Clic au centre de l'icône de suppression	atteint le bouton, pas le lien

Trois corrections de lisibilité l'accompagnent : une **pastille d'initiale** qui ancre l'œil dans une liste où toutes les lignes se ressemblaient, des **séparateurs en point** dans les métadonnées qui formaient un seul bloc gris, et un état « **Pas encore analysé** » là où il n'y avait qu'un vide quand le cours n'avait ni résumé ni quiz.

Un `Chargement…` en texte nu a été remplacé par le squelette utilisé partout ailleurs. Il a été repéré par accident : le panneau du navigateur s'est suspendu pendant l'audit, la requête est restée en suspens, et l'écran a affiché ce mot seul indéfiniment. L'incident venait de l'outil, pas de l'application — mais il a montré ce que voit un utilisateur dont le réseau décroche.

Et une valeur en dur de plus retirée du TSX : `style={{ fontSize: 15 }}`.

Étape 4 — l'examen blanc et son corrigé

Une régression fonctionnelle, introduite à l'étape 1. Rendre l'en-tête collant l'a mis en concurrence avec la barre de chronomètre, collante elle aussi, à `top: 0`. L'en-tête a gagné : **pendant une épreuve chronométrée, le compte à rebours disparaissait entièrement.** Mesuré — barre à 101 px de bas, en-tête à 153, `z-index` 5 contre 20.

Elle n'aurait pas été vue sur une capture d'écran prise en haut de page. Elle n'apparaît qu'en défilant, pendant un examen, c'est-à-dire exactement au moment où le chiffre compte.

Le correctif refuse le nombre magique. Figer la hauteur de l'en-tête dans le CSS reproduirait le `calc(100vh - 69px)` retiré la veille : elle change avec la largeur, la navigation passant à la ligne sur téléphone. Un `ResizeObserver` la mesure et la publie dans `--hauteur-entete` ; la barre s'y réfère, et `scroll-padding-top` avec elle, pour qu'aucun ancrage ne dépose du contenu sous l'en-tête.

Un piège au passage : `ResizeObserver` rend `contentRect`, qui **exclut le remplissage et la bordure**. Première mesure : 132 px pour un en-tête qui en fait 153 — le chronomètre restait caché de 21 px. Corrigé en relisant la boîte complète. *Une mesure fausse est pire qu'une absence de mesure : elle a l'air juste.*

Le corrigé doit survivre au projecteur

Les bonnes et mauvaises réponses se distinguaient par la seule couleur. Elles portent désormais un **marqueur** — ✓ et ✕ — en plus du fond. Un corrigé est projeté en soutenance, parfois imprimé, et lu par des gens dont 8 % des hommes confondent le rouge et le vert.

La **citation du cours** passe du gris au fond teinté de marque avec un filet coloré. C'est la preuve de l'ancrage, l'argument central du projet : elle ne doit pas être le texte le plus effacé de l'écran.

L'option sélectionnée pendant l'épreuve est marquée par une **ombre interne** plutôt qu'une bordure plus épaisse : épaissir la bordure décale le texte d'un pixel et fait sauter la liste entière au clic.

Une couleur corrigée par cohérence, pas par goût

`--succes` sur son propre fond clair mesurait **4,57:1** dans le corrigé — la même marge dérisoire refusée le matin même sur l'écran de connexion. Foncé.

Couleur d'état sur son fond	Avant	Après
Succès	4,57	**6,04**
Erreur	5,30	5,30
Alerte	4,98	4,98
Info	5,49	5,49

La règle vaut pour toutes les couleurs, pas seulement pour celles qu'on regarde au moment où on l'énonce.

Étape 5 — la densité de la page Consommation

Le tableau devient un graphique sans gagner une colonne. Sept colonnes de chiffres ne disent pas quel module pèse le plus. La cellule de coût porte désormais une barre proportionnelle, dessinée en CSS à partir

d'une propriété `--part` posée par le composant. Lecture immédiate : Quiz 1,00 · Résumé 0,67 · Tuteur 0,44.

S'y ajoutent des lignes alternées — sur sept colonnes, l'œil perd sa ligne — un en-tête en petites capitales avec un filet plus marqué, et une mise en avant du coût parmi les cinq chiffres clés : **cinq chiffres de même poids, c'est aucun chiffre.**

Un en-tête de tableau collant, essayé puis retiré. Le tableau vit dans un conteneur `overflow-x: auto`, qui devient alors son contexte de défilement : l'en-tête se figeait au milieu du tableau et recouvrait une ligne de données. Un `thead` collant suppose que le tableau soit lui-même la zone qui défile.

La régression la plus instructive de la refonte

Première vérification de cette page sur téléphone : **522 px de débordement horizontal**, et le conteneur censé faire défiler le tableau ne défilait pas.

J'ai diagnostiqué **deux fois de suite une mauvaise cause**, avec aplomb : d'abord `min-width: auto` sur le conteneur du tableau, puis sur le `main`. J'ai écrit dans le fichier un commentaire affirmant que le défaut était antérieur à la refonte. Les deux correctifs n'ont rien changé, et l'affirmation était fausse.

Ce qui a tranché : une comparaison empirique de cinq candidats appliqués en direct, et un test de bissection — remettre `#root` en `display: block` ramenait le débordement de 522 à **zéro**, établissant que la régression venait bien de l'étape 2.

Candidat	Débordement	Largeur de la page
état constaté	522 px	897 px
`min-width: 0` sur le conteneur du tableau	522 px	897 px
`min-width: 0` sur le `main`	522 px	897 px
`overflow-x: clip` sur `#root`	**0**	897 px
`width: 100%` sur le `main`	**0**	**375 px**

`overflow-x: clip` supprimait la barre de défilement en laissant la page large de 897 px : il **masque le symptôme**. Écarté — une correction qui rend le défaut invisible sans le supprimer est pire que pas de correction.

La cause réelle : rendre `#root` flexible à l'étape 2 a transformé chaque `main` en enfant flex, dont la largeur `auto` se résout sur le contenu et non sur le conteneur. C'est la **page** qui débordait, pas le tableau — ce qui explique pourquoi son conteneur à défilement ne servait plus à rien.

Leçon. Une hypothèse plausible, écrite en commentaire avec assurance, reste une hypothèse. Celle-ci était fausse deux fois. Le coût d'un test empirique de cinq lignes était nul ; celui d'un commentaire faux laissé dans le code aurait été payé par le prochain qui l'aurait cru.

Étape 6 — la fiche de cours, et la pastille de coût

Les onglets étaient stylés par une douzaine de valeurs écrites en ligne — couleurs, graisses, épaisseur du filet, espacements — en contradiction directe avec la règle que la feuille de style énonce dans son propre en-

tête : *« aucune couleur, ombre, rayon ou taille de texte n'est écrite en dur ailleurs »*. Passés en classes.

La pastille de coût. C'est l'ajout qui compte sur cet écran. Trois onglets déclenchent un appel au modèle, le quatrième lit la base. L'interface le disait en prose, en bas de page, après coup. Chaque onglet porte désormais **« 1 appel »** ou **« gratuit »**, à l'endroit exact où la décision se prend.

La singularité de ce projet n'est pas d'appeler un modèle — tout le monde le fait — c'est de dire ce que ça coûte. Le dire une fois dans le rapport et nulle part dans l'écran, c'était la garder pour soi.

La classe est **réutilisable** : elle a vocation à se poser sur toute action pouvant consommer un appel.

Élément	Contraste
Pastille « 1 appel »	4,98
Pastille « gratuit »	6,04
Onglet actif	9,56
Onglet inactif	5,26

Troisième `Chargement…` en texte nu remplacé par le squelette. Les trois étaient dans trois fichiers différents, écrits à trois moments différents — le genre d'incohérence qu'un composant partagé existe précisément pour éviter, quand on pense à s'en servir.

Sur téléphone, quatre onglets portant chacun une pastille ne tiennent pas sur 375 px : la barre défile dans son propre cadre, comme la navigation principale. Vérifié — zéro débordement de page.

---

022 — Les messages d'erreur atteignent enfin l'écran

Date : 16 octobre 2026 · **État** : accepté

Le défaut. Le serveur compose des messages précis : « Ce cours fait 475 997 caractères, soit 275 997 de trop », « Ouvrez le fichier dans PowerPoint et enregistrez-le en .pptx », « Réessayez dans 12 secondes ». Le client les **jetait**. `api.ts` construisait `new ApiError(code, details)` sans le message, et la classe retombait sur une table de onze phrases génériques.

Mesuré en envoyant un `.zip` à l'import :

Ce que le serveur répond	« Format non reconnu. Formats acceptés : PDF, Word (.docx) et PowerPoint (.pptx). »
Ce que l'étudiant lisait	« Certaines informations sont invalides. »

Tout le travail de la décision 016 sur la taxonomie d'erreurs n'atteignait jamais l'écran. C'est le genre d'écart le plus coûteux : le soin est réel, la dépense aussi, et le bénéfice nul.

Pourquoi le client recompose au lieu d'afficher la phrase du serveur

Afficher directement le message réglait le problème en une ligne. Il fige pourtant le français dans **51 levées d'exception** côté serveur, ce qui rend la traduction prévue à l'étape 5 impossible sans toutes les réécrire.

Le serveur envoie déjà des `details` structurés — `{caracteres, limite}`, `{extension, acceptes}`, `{attente_s}`. Le client compose à partir d'eux, dans la langue active. Trois niveaux de repli, dans l'ordre :

1. `details` reconnus → message composé côté client, **traduisible** ;
2. message du serveur → précis, mais figé en français ;
3. table par code → générique, dernier recours.

Quinze des 51 levées portent des détails ; ce sont les plus utiles. Les 36 autres passent par le niveau 2 et gagnent quand même en précision. Aucune ligne du serveur n'a été touchée.

Chaque composeur rend `null` quand les détails attendus manquent, pour ne jamais produire « soit undefined caractères de trop ».

Vérifié de bout en bout dans l'interface, pas seulement par test : un cours de 206 799 caractères affiche désormais *« soit 6 799 de trop. La limite est de 200 000. Découpez-le en plusieurs cours. »*

Les premiers tests du front, et pourquoi ce sujet

Le projet avait 162 tests côté serveur et **zéro côté interface**. Vitest est installé, et les treize premiers tests portent sur ce composeur.

Le sujet n'est pas choisi au hasard : la refonte visuelle venait d'introduire **trois régressions en une soirée** — navigation débordante, chronomètre d'examen caché, page large de 897 px sur un écran de 375. Aucune n'était visible sur une capture d'écran, et rien ne les aurait arrêtées.

Un des treize a échoué au premier essai, pour une bonne raison : `toLocaleString('fr-FR')` sépare les milliers par une **espace fine insécable** (U+202F), pas par une espace ordinaire. C'était le test qui avait tort, pas le code. Rendu indifférent au type d'espace — un piège qui aurait resurgi au premier test de formatage de nombres.

Les tests sont **ajoutés à l'intégration continue** dans le même commit : une suite qui ne tourne pas à chaque poussée ne protège personne.

---

023 — Correctifs d'usage : formats texte, états vides, session expirée

Date : 16 octobre 2026 · **État** : accepté

Cinq points sans rapport entre eux, réunis parce qu'ils relèvent tous du même constat : des cas que l'application traitait bien *ailleurs* et pas *ici*.

`.txt` et `.md`, et le piège de l'encodage

Trois lignes de code — et un piège qui n'en est pas un. Un fichier produit sous Windows est souvent en **cp1252** : le décoder en UTF-8 lève une exception au premier caractère accentué, donc, dans un cours

français, dès la première ligne. Le lecteur tente `utf-8-sig`, puis `utf-8`, puis `cp1252`, et `latin-1` en dernier recours.

L'ordre n'est pas indifférent : cp1252 accepte presque n'importe quel octet et ne lève donc jamais. Le tester en premier reviendrait à ne jamais essayer UTF-8. Vérifié en retirant le repli : un test tombe.

Le Markdown n'est pas converti. Ses marques sont du texte que le modèle lit très bien, et les retirer coûterait une dépendance pour perdre la structure des titres.

Trois états que l'application gérait ailleurs

La recherche sans cours. Un inscrit sans aucun support voyait un champ de recherche et « Tapez un mot du cours » — une invitation à chercher dans le vide. Examen blanc et Consommation traitaient déjà ce cas.

Deux boutons primaires rivaux. L'état vide de la bibliothèque portait « Ajouter un cours » et « Ajouter mon premier cours », tous deux en rouge plein. Le premier passe en secondaire quand la liste est vide.

Les chargements muets. Un appel au modèle prend deux à huit secondes derrière un squelette silencieux. Les trois modules annoncent maintenant ce qui se passe — « Lecture du cours, puis rédaction de la synthèse… ». Les lectures en base restent muettes : les annoncer serait du bruit.

La session expirée, et deux erreurs en la corrigeant

Une session expirée renvoyait vers l'écran de connexion **sans un mot**. L'étudiant perdait sa page en pleine révision sans savoir pourquoi.

Le correctif a demandé trois essais, et les deux premiers sont instructifs :

1. **Premier essai** — afficher le bandeau depuis l'état de navigation. Il réapparaissait à chaque rechargement de l'écran de connexion, longtemps après l'événement : `history.state` **survit au rechargement**, ce que je ne savais pas avant de l'observer.
2. **Deuxième essai** — nettoyer l'état au montage. Le bandeau ne s'affichait plus **du tout** : l'effet s'exécute juste après le premier rendu, donc l'utilisateur n'avait rien le temps de lire. *J'ai cassé la fonctionnalité en corrigeant son effet de bord.*
3. **Troisième** — capturer le drapeau dans l'état du composant au premier rendu, puis nettoyer l'historique. La page de retour, elle, est conservée.

Trois propriétés vérifiées séparément : le message s'affiche à l'expiration, il **ne s'affiche pas** pour quelqu'un qui ne s'est jamais connecté, et il disparaît après un rechargement sans emporter la page de retour.

Leçon. Les deux premiers essais passaient le test évident — « le message s'affiche-t-il ? » — et échouaient sur un cas voisin. Un correctif d'état transitoire se vérifie dans les trois sens : il apparaît quand il faut, il n'apparaît pas quand il ne faut pas, et il disparaît.

---

024 — Traduction français / anglais, et les accents de l'interface

Date : 16 octobre 2026 · **État** : accepté · *premier lot sur deux*

Sans dépendance, et pourquoi

Deux langues, un dictionnaire plat, aucun pluriel complexe, aucun chargement différé. `react-i18next` apporterait une configuration, un format de fichiers et une quarantaine de kilo-octets pour un `Record` et un contexte — une centaine de lignes écrites ici. Même logique que les appels d'API sans SDK (DECISIONS 003) et les PDF sans dépendance système (012).

Le dictionnaire français **définit le type** ; l'anglais est contraint à `Record<keyof typeof FR, string>`. Une clé oubliée est une erreur de compilation, pas une étiquette vide découverte par un utilisateur.

Ce que l'extraction a corrigé, et qui vaut autant que la traduction

L'interface était en français sans accents — « Aucun resume pour ce cours », « 8 caracteres minimum », « Detaille », « Pas encore analyse ». Les prompts avaient été accentués en v3 (DECISIONS 015) ; l'interface, jamais.

Extraire chaque chaîne oblige à la relire une par une. C'est là que le défaut se répare, et c'est l'argument qui rendait ce chantier rentable au-delà de la traduction elle-même.

Les sept `'fr-FR'` écrits en dur — nombres et dates — suivent désormais la langue : un étudiant en anglais lit « 1,566 characters · Added 13 Oct 2026 » là où il lisait « 1 566 » avec une espace fine.

Un test anti-régression qui ne protégeait rien

Un test vérifie qu'aucune chaîne française ne porte un mot connu sans accent. Vérifié en réintroduisant « Pas encore analyse, aucun resume genere » : **les dix-neuf tests passaient.**

Deux causes cumulées, et la seconde est la plus instructive :

1. `String.match()` **sans le drapeau** `g` ne rend que la première occurrence. Ici c'était « analyse », légitimement sans accent, et mon filtre d'exception avalait alors toute la chaîne.
2. Réécrit avec un gabarit JavaScript, `\b` y désigne un **caractère d'échappement arrière**, pas une limite de mot. Le test restait inerte.

Corrigé, il attrape « resume » et « genere » tout en ignorant « analyse ».

C'est la cinquième fois dans ce projet qu'un test vert ne protège rien. Les cinq fois, c'est une **mutation volontaire** qui l'a révélé, jamais une relecture.

Ce qui n'est pas traduit, et pourquoi

- **Les sorties du modèle restent en français.** Paramétrer le fragment `LANGUE` créerait une version de prompt, et les mesures publiées du banc d'essai ne couvrent que le français. Le tuteur fait exception sans qu'on touche à rien : son prompt dit déjà « réponds dans la langue de la question ».
- **Les messages d'erreur du serveur.** Le client les recompose à partir des `details` structurés (DECISIONS 022), donc dans la langue active. Ceux qui n'ont pas de détails s'affichent en français.

Deux trouvailles des lots suivants

Une collision de noms, attrapée par le compilateur : dans `ProgressionPanel`, la variable de boucle des tentatives s'appelait `t`, comme la fonction de traduction. Deux `t` différents dans la même portée — et le

code compilait encore par hasard, puisque `t.score` reste valide sur une tentative. Renommée.

De la prose d'interface dans une réponse d'API. La page de consommation passait entièrement en anglais, sauf un paragraphe. Il venait du serveur : `_gratuit()` renvoyait un champ `explication` que le client affichait tel quel. Une phrase destinée à l'écran n'a rien à faire dans une réponse d'API — elle a rejoint le dictionnaire, et le champ a disparu du schéma.

Le garde-fou ne passe pas par le contexte

Le composant qui rattrape les effondrements de rendu traduit en lisant la langue **directement dans le stockage**, sans le hook. C'est délibéré : si c'était le fournisseur de traduction qui avait échoué, appeler son hook ici relèverait la même exception et laisserait l'utilisateur devant une page blanche. Il retombe sur le français au moindre doute.

Couverture

Les onze écrans sont traduits : en-tête, authentification, bibliothèque, fiche de cours et ses quatre panneaux, recherche, examen blanc, consommation, page introuvable et garde-fou. Environ **200 chaînes**, toutes accentuées côté français.